

单个请求到达后的长期成本感知卸载流程

从信息采集、预测、动作过滤到 Double DQN 长期价值评估，并用执行反馈持续训练

输入信息

Request 信息

入口节点与会话 ID
Prompt、上下文、SLA

CEC 网络信息

节点负载与剩余显存
链路有效带宽与模型实例

KV Manager 状态

Block Directory

位置、版本、前缀哈希

Cache Policy

副本保留、驱逐、增量同步

图中关键思想

当前请求不只看即时延迟，
还要看动作对后续 KV 位置
和未来移动入口的长期影响。

1 信息采集

合并 request 信息
读取 CEC 遥测
查询 KV 分布

2 预测与状态组合

预测未来入口分布
预测当前输出长度
形成决策状态

3 候选动作生成

枚举计算节点
选择 KV 获取方式
形成候选动作集

4 即时成本估计

估计通信与 KV 同步
估计 prefill/decode
估计 E2E 与显存

5 可行性过滤

按 SLA 过滤
按显存过滤
按版本和节点可用性过滤

6 长期价值评估

Double DQN 评估可行动作
移动概率进入未来价值
比较长期累计成本

7 选择并执行

选择长期成本最低动作
路由到计算节点
复用/同步/重算 KV

过滤后保留的动作

节点 A + reuse

节点 B + sync

节点 C + recompute

不可行动作不进入后续价值比较，例如显存不足、SLA 风险过高或缺少一致 KV 版本。

执行反馈与训练闭环

执行观测

实际 E2E、输出长度
KV 增量、传输量、显存变化

Replay Buffer

保存状态、动作、成本
保存下一状态

模型更新

更新长度/移动预测与成本模型
训练 Double DQN 在线网络

反馈更新后用于下一次请求

汇入状态构造